

De un Árbol a un Bosque: Modelos de Ensamble en la Gestión Pública

Las agencias públicas se enfrentan cada vez más a problemas que parecen "econométricos" en su motivación pero "predictivos" en su ejecución: seleccionar qué empresas auditar por evasión fiscal, señalar a estudiantes en riesgo de abandono o atacar a la escasa capacidad de inspección donde se previene el mayor daño. La economía moderna ha reconocido explícitamente la predicción como una tarea distinta de la identificación causal, con diferentes normas de validación (rendimiento fuera de muestra, validación cruzada) y diferentes modos de fallo (sobreajuste, desplazamiento de distribución). [1]

Los métodos de conjunto —modelos que combinan a muchos estudiantes "débiles" en un predictor más fuerte— están en el centro de este conjunto de herramientas predictivas. Su valor no es que sustituyan el razonamiento económico, sino que lo operacionalizan a gran escala: pueden absorber datos administrativos de gran dimensión, captar no linealidades e interacciones, y producir puntuaciones de riesgo que ayudan a asignar recursos públicos limitados. [2]

A continuación, una guía técnica pero accesible para economistas sobre las dos familias principales de conjuntos utilizadas en la gestión pública: **Random Forests** (embolsado) y **Gradient Boosting** (por ejemplo, XGBoost/LightGBM). El énfasis es pedagógico: por qué funcionan estos modelos, qué intercambian y cómo interpretarlos de forma responsable en entornos de políticas de alto riesgo. [3]

Bosques aleatorios y la sabiduría de las multitudes

El bagging ("agregación bootstrap") parte de una receta sencilla: extraer muchas muestras bootstrap de los datos de entrenamiento (muestreo con reemplazo), ajustar un modelo por cada muestra bootstrap y luego agregar las predicciones—**promediando** para regresión o **voto mayoritario** para clasificación. Esta es la idea central de **los predictores de embolsas**

introducida por Leo Breiman[4]: se entrenan múltiples versiones de un predictor con réplicas bootstrap y se agregan para mejorar el rendimiento. [5]

¿Por qué ayuda el bagging? Los árboles de decisión son potentes pero **inestables**: pequeñas perturbaciones de la muestra de entrenamiento pueden dar lugar a divisiones y predicciones muy distintas, lo que es la esencia de la alta varianza en la descomposición sesgo–varianza. El envasado reduce la varianza porque promediar muchas estimaciones ruidosas cancela el ruido de muestreo idiosincrático, especialmente cuando el aprendiz base es inestable (los árboles son el ejemplo canónico). [6]

Random Forests añade un segundo ingrediente al bagging: la **aleatoriedad de características**. Además de las filas de muestreo bootstrap, cada división considera solo un subconjunto aleatorio de predictores. El propósito es **descorrelacionar** los árboles: si todos los árboles ven el mismo predictor más fuerte en cada división, se vuelven similares y el promedio ayuda menos. El artículo de Breiman sobre Random Forests formaliza esta intuición: el error de generalización depende de la fuerza del árbol y la correlación entre árboles, y la inyección de aleatoriedad puede reducir la correlación. [7]

En la práctica, por eso los bosques aleatorios suelen describirse como máquinas de "control de varianza": muchos árboles de alta varianza se convierten en un conjunto de menor varianza mediante el promediado, y la selección aleatoria de características ayuda a que ese promediado sea efectivo al limitar la correlación. La documentación de scikit-learn resume esta lógica de ingeniería directamente: el modelo ajusta muchos árboles en (sub)muestras y utiliza el promediado para mejorar la precisión predictiva y el sobreajuste de controles. [8]

La analogía de la "sabiduría de las multitudes" es más que una metáfora; es un principio estadístico. Cuando se agregan muchas estimaciones independientes (o débilmente correlacionadas), la estimación colectiva resultante puede acercarse más a la verdad que una estimación individual típica, ilustrada de forma famosa por historias de estimación de multitudes como el concurso de peso ganadero de Francis Galton [9] relatado en relatos de divulgación científica. Los bosques aleatorios son una versión de

aprendizaje automático de esta lógica: cada árbol es un "juez" imperfecto, y el bosque es el juicio agregado. [10]

Aumento de gradiente como corrección iterativa de errores

Si los bosques aleatorios se parecen a una votación simultánea, **el impulso** se asemeja a un proceso de aprendizaje disciplinado y secuencial. En el gradient boosting, los modelos se construyen **de forma aditiva**: empiezas con un predictor base simple, calculas los errores (residuos) de ese predictor y luego ajustas el siguiente modelo a esos errores. Repetir esto muchas veces produce un predictor fuerte: cada nuevo componente está especializado en corregir lo que el conjunto actual aún falla. Esta formulación proviene del marco de la máquina de aumento de gradiente desarrollado por Jerome H. Friedman[11], donde cada paso aproxima un descenso en el gradiente de una función de pérdida (de ahí el "gradiente" de potenciación). [12]

Esta lógica de "corrección de errores" se corresponde de forma natural con el aprendizaje de políticas. Muchos programas públicos evolucionan a través de ciclos iterativos: implementan una regla de segmentación, miden errores (fugas a hogares no elegibles, exclusión de hogares elegibles) y luego revisan los criterios. El impulso es una iteración algorítmica de políticas: cada ronda centra la atención en las observaciones menos atendidas por rondas anteriores, exactamente como un rediseño de programa podría centrarse en bolsillos de exclusión crónica o patrones persistentes de fraude que las reglas de riesgo anteriores pasaron por alto. La analogía debe usarse con cuidado (los algoritmos no codifican automáticamente objetivos normativos), pero la estructura iterativa es estructuralmente similar. [13]

Dos implementaciones de impulso ampliamente utilizadas en trabajos aplicados son **XGBoost** y **LightGBM**. **XGBoost**, de Tianqi Chen[14] y Carlos Guestrin[15], es un sistema escalable de aumento de árboles que enfatiza la eficiencia computacional (algoritmos conscientes de la esparsidad, búsqueda aproximada de escindimientos) y la regularización para mejorar la generalización. [16]

LightGBM, asociado con Guolin Ke[17] y coautores, se centra en la velocidad y escalabilidad mediante técnicas como la búsqueda de divisiones basadas en histogramas y estrategias de muestreo/agrupamiento

(notablemente GOSS y EFB en el artículo original), buscando preservar el rendimiento predictivo. [18]

Económicamente, la implicación práctica es que el aumento suele lograr una precisión predictiva muy fuerte en conjuntos de datos administrativos tabulares, precisamente el entorno de muchas aplicaciones del sector público (fiscal, prestaciones, educación). La desventaja es que el aumento de potencia puede sobreajustarse si se lleva demasiado lejos sin regularización o parada temprana, porque el proceso secuencial puede seguir ajustando ruido residual cada vez más idiosincrático. [19]

Importancia variable más allá del valor p

Una pregunta común en el análisis de políticas es: "¿Qué factores determinan el resultado?" En la econometría tradicional, esto se aborda a menudo mediante estimaciones de coeficientes y **valores p**. Pero los valores p suelen ser malinterpretados y, por diseño, responden a una pregunta específica condicionada a un modelo específico y sus supuestos. La Asociación Estadística Americana [20] advierte explícitamente que los valores p **no** miden la probabilidad de que una hipótesis sea verdadera, **no** miden el tamaño o la importancia del efecto y, por sí solos, no proporcionan una buena medida de evidencia para un modelo o hipótesis. [21]

Los modelos de conjunto ofrecen una perspectiva diferente: **la contribución predictiva**. En lugar de preguntar si un parámetro difiere de cero bajo una especificación paramétrica, los conjuntos preguntan cuánto ayuda una variable al modelo a predecir fuera de la muestra. Esto no es "mejor" en un sentido causal, pero puede estar más alineado con tareas gerenciales como la puntuación de riesgos o la triaje, donde el objetivo operativo es el rendimiento predictivo bajo limitaciones de recursos. Los economistas han enfatizado esta distinción entre predicción e inferencia como central al importar aprendizaje automático al trabajo económico. [1]

Sin embargo, la "importancia de las características" no es una sola cosa: es una familia de diagnósticos con supuestos diferentes.

Una medida ampliamente utilizada en conjuntos de árboles es la **importancia basada en impurezas** (a veces llamada disminución media de

impurezas). Resume cuánto reduce una característica la impureza a través de divisiones. Sin embargo, esta medida puede estar sesgada, especialmente favoreciendo variables continuas o de alta cardinalidad. La documentación de scikit-learn ilustra este problema y motiva medidas de importancia alternativa. [22]

Una alternativa robusta es la **importancia de la característica por permutación**: baraja los valores de una característica y observa el deterioro resultante en la puntuación del modelo. Esta idea es agnóstica respecto al modelo y puede calcularse en un conjunto de pruebas extendido, proporcionando una interpretación directa: "¿Cuánta capacidad predictiva perdemos si se destruye la información de esta característica?" La documentación de scikit-learn describe este procedimiento y su razonamiento, y conecta históricamente con conceptos de importancia de variables de bosque aleatorio. [23]

Una tercera familia de herramientas explica las predicciones de forma más detallada usando la lógica de valores de Shapley. **SHAP** (Shapley Additive ExPlanations), introducida por Scott M. Lundberg[24] y Tapani Saar-Tsechansky proporciona atribuciones de características para predicciones individuales con propiedades axiomáticas; trabajos posteriores extienden SHAP de forma eficiente a conjuntos de árboles (TreeSHAP y variantes relacionadas). [25]

Desde el punto de vista de la gestión pública, estas herramientas ayudan a responder preguntas prácticas como: "¿Estamos marcando a las empresas principalmente por anomalías en la red de facturación, picos repentinos de créditos de IVA o riesgo a nivel sectorial?" o "¿Las predicciones de riesgo de abandono están impulsadas principalmente por trayectorias de asistencia, choques de calificación o limitaciones de distancia al colegio?" Es importante destacar que estos son **"impulsores" predictivos**, no palancas causales automáticas. La importancia de las variables puede cambiar entre modelos igualmente precisos (el fenómeno "Rashomon"), y los predictores correlacionados complican la atribución. El trabajo sobre la dependencia de modelos y la "dependencia de clases de modelo" formaliza cómo puede variar la importancia a lo largo del conjunto de modelos con buen rendimiento. [26]

Interpretabilidad y precisión en las decisiones públicas

Los conjuntos intensifican una tensión central en la analítica del sector público: **interpretabilidad frente a precisión predictiva**. Modelos simples—regresión logística, árboles superficiales, listas de reglas—son más fáciles de auditar, justificar y cuestionar. Los conjuntos complejos—bosques aleatorios, aumento de gradientes—suelen predecir mejor, pero pueden ser más difíciles de explicar y gobernar.

Esta tensión no es meramente técnica; es institucional. En entornos de alto riesgo (justicia penal, salud, elegibilidad de prestaciones), Cynthia Rudin[27] sostiene que los modelos inherentemente interpretables deberían preferirse a menudo sobre los modelos de caja negra más explicaciones a posteriori, porque las explicaciones pueden ser engañosas y la rendición de cuentas exige transparencia. [28]

La guía de IA del sector público refleja esta preocupación de gobernanza. Los principios de IA de la OCDE[29] enfatizan la transparencia y la explicabilidad adecuadas al contexto, presentándolos como elementos de una IA fiable junto a la robustez y la rendición de cuentas. [30]

Una regla práctica para los gobiernos es tratar la elección de modelos como **un diseño de políticas bajo restricciones**, no como una competición en la tabla de clasificación. Cuando la salida determina directamente derechos, obligaciones o acceso (por ejemplo, la negación de un beneficio), la "legibilidad" de la regla de decisión puede ser tan importante como los beneficios marginales en AUC. Cuando el modelo se utiliza como **herramienta de selección** para priorizar la escasa capacidad investigadora (por ejemplo, seleccionando al 1–5% superior de las firmas para auditoría), un mayor poder predictivo puede suponer una complejidad adicional, siempre que existan monitorizaciones, auditorías por sesgo y salvaguardas de debido proceso. [31]

La interpretabilidad no es binaria. La práctica moderna suele emplear un enfoque por capas: un conjunto sólido para la predicción más artefactos transparentes de "inspección del modelo" (importancia de permutación, dependencia parcial, resúmenes SHAP) para supervisar, recordando que estos son ayudas explicativas y no pruebas causales. El marco de

interpretabilidad de Christoph Molnar es útil para estructurar esta discusión y seleccionar herramientas explicativas apropiadas al riesgo y al público. [32]

Aplicados para abandono escolar, fraude fiscal y evaluación de impacto

En la **predicción del riesgo de abandono**, los sistemas educativos construyen cada vez más indicadores de alerta temprana a partir de la asistencia, las notas y las señales de comportamiento o administrativas. Trabajos recientes de minería de datos educativos evalúan modelos como XGBoost para la predicción temprana de estudiantes en riesgo, ilustrando por qué el boosting resulta atractivo: gestiona interacciones no lineales y puede incorporar muchos predictores sin necesidad de una especificación paramétrica. [33]

Desde una perspectiva política, la clave es alinear el modelo con la intervención. Si la capacidad de intervención es limitada (por ejemplo, los orientadores solo pueden hacer seguimiento con el 5% de los estudiantes), el problema de decisión se asemeja a la "segmentación top-k", y la evaluación debería centrarse en si el modelo clasifica a los estudiantes realmente en riesgo de forma alta, a menudo favoreciendo métricas vinculadas a compensaciones de recuerdo/precisión en lugar de precisión pura. Este énfasis en la validación operativa es coherente con la forma en que los economistas diferencian las tareas predictivas de las cuestiones causales. [1]

En **fraude fiscal y selección de auditorías**, la lógica es aún más clara: las administraciones no pueden auditar a todos, por lo que priorizan los casos según el riesgo previsto y el rendimiento esperado. Los informes de la OCDE documentan cómo las administraciones fiscales utilizan "análisis avanzados" para la identificación de riesgos y la selección de casos, y material más reciente de la OCDE describe unidades institucionalizadas de análisis predictivo (por ejemplo, centros de competencia) destinadas a mejorar la segmentación de auditorías y la detección de fraudes. [34]

De manera similar, el Fondo Monetario Internacional [35] ha publicado guías prácticas sobre análisis para la gestión del riesgo de cumplimiento, incluyendo flujos de trabajo utilizando aprendizaje automático para

seleccionar casos de auditoría y evaluar el poder predictivo, destacando que el despliegue de modelos está integrado en procesos organizativos, no solo en el código. [36]

¿Dónde encaja la **evaluación de impacto** ? Los conjuntos no son solo para predicciones; Los "bosques causales" y los "bosques aleatorios generalizados" amplían la lógica del bosque aleatorio para estimar efectos heterogéneos del tratamiento bajo el marco de resultados potenciales. Esto es importante para la gestión pública porque la segmentación suele tener que ver con *el impacto*, no solo con la necesidad: quizá quieras identificar quién se beneficia más de las tutorías, inspecciones o traslados. El marco forestal causal desarrollado por Wager y Athey, y el marco generalizado de bosque aleatorio por Athey, Tibshirani y Wager, proporcionan herramientas formales (y teoría asintótica) para este análisis de heterogeneidad, uniendo la flexibilidad del estilo de predicción con objetivos de inferencia. [37]

En resumen: un gobierno puede usar el boosting o los bosques aleatorios para predecir el riesgo de abandono escolar o la probabilidad de fraude, y puede emplear métodos causales basados en bosques para estimar qué intervenciones funcionan mejor para qué grupos, siempre que se cumplan la calidad de los datos, las suposiciones de identificación y las restricciones de gobernanza. [38]

Conclusión

Random Forests y Gradient Boosting representan dos filosofías de aprendizaje distintas que son ambas muy relevantes para la administración pública. Los bosques aleatorios reducen la varianza agregando muchos árboles parcialmente independientes contruidos sobre muestras bootstrap y subconjuntos de características aleatorias, una "sabiduría de las multitudes" algorítmica que estabiliza a los aprendices inherentemente inestables. [39]

Los métodos de impulso construyen modelos secuencialmente, corrigiendo errores previos mediante optimización funcional basada en gradientes, e implementaciones modernas como XGBoost y LightGBM escalan esta idea a grandes conjuntos de datos administrativos. [19]

Para los economistas, la clave no solo es una mayor precisión, sino también un diagnóstico más rico: pueden aparecer herramientas de importancia de características y atribución de qué variables depende el sistema para la predicción, a menudo más informativas operativamente que los valores p en una sola especificación paramétrica, exigiendo precaución sobre la causalidad y los predictores correlacionados. [40]

Por último, la elección del modelo en el gobierno debe enmarcarse como un problema de gobernanza: seleccionar un punto en la frontera interpretabilidad–precisión apropiado para las apuestas, coherente con las normas de transparencia/explicabilidad e integrado en flujos de trabajo institucionales auditables. [41]

[1] [2] Machine Learning: An Applied Econometric Approach

https://www.aeaweb.org/articles?id=10.1257%2Fjep.31.2.87&utm_source=chatgpt.com

[3] [6] [27] An Introduction to Statistical Learning

<https://www.casact.org/sites/default/files/2022-12/James-G.-et-al.-2nd-edition-Springer-2021.pdf>

[4] [23] 5.2. Permutation feature importance

https://scikit-learn.org/stable/modules/permutation_importance.html

[5] [39] Bagging Predictors

<https://sci2s.ugr.es/keel/pdf/algorithm/articulo/1996-ML-Breiman-Bagging%20Predictors.pdf>

[7] 1 RANDOM FORESTS Leo Breiman Statistics Department ...

<https://www.stat.berkeley.edu/~breiman/randomforest2001.pdf>

[8] RandomForestClassifier — scikit-learn 1.8.0 documentation

<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

[9] [12] [13] [19] [24] Greedy function approximation: A gradient boosting machine.

<https://projecteuclid.org/journals/annals-of-statistics/volume-29/issue-5/Greedy-function-approximation-A-gradient-boosting-machine/10.1214/aos/1013203451.full>

[10] The Real Wisdom of the Crowds

<https://www.nationalgeographic.com/science/article/the-real-wisdom-of-the-crowds>

[11] [38] The Impact of Machine Learning on Economics

<https://www.nber.org/books-and-chapters/economics-artificial-intelligence-agenda/impact-machine-learning-economics>

[14] [25] A Unified Approach to Interpreting Model Predictions

<https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>

[15] [30] AI principles

<https://www.oecd.org/en/topics/sub-issues/ai-principles.html>

[16] XGBoost: A Scalable Tree Boosting System

<https://arxiv.org/abs/1603.02754>

[17] [33] Early Prediction of Student Dropout in Higher Education ...

<https://educationaldatamining.org/edm2024/proceedings/2024.EDM-short-papers.32/index.html>

[18] LightGBM: A Highly Efficient Gradient Boosting Decision Tree

<https://proceedings.neurips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree.pdf>

[20] [28] [31] [35] [41] Stop explaining black box machine learning models for ...

<https://www.nature.com/articles/s42256-019-0048-x>

[21] [40] p-valuestatement.pdf

<https://www.amstat.org/asa/files/pdfs/p-valuestatement.pdf>

[22] Permutation Importance vs Random Forest Feature ...

https://scikit-learn.org/1.6/auto_examples/inspection/plot_permutation_importance.html

[26] Learning a Variable's Importance by Studying an Entire ...

<https://jmlr.csail.mit.edu/papers/volume20/18-760/18-760.pdf>

[29] [32] Interpretable Machine Learning

https://originalstatic.aminer.cn/misc/pdf/Molnar-interpretable-machine-learning_compressed.pdf

[34] Advanced Analytics for Better Tax Administration (EN)

https://www.oecd.org/content/dam/oecd/en/publications/reports/2016/05/advanced-analytics-for-better-tax-administration_g1g6743d/9789264256453-en.pdf

[36] Tax Administration: Essential Analytics for Compliance ...

<https://www.imf.org/-/media/files/publications/tnm/2024/english/tnmea2024001.pdf>

[37] Estimation and Inference of Heterogeneous Treatment ...

<https://www.tandfonline.com/doi/full/10.1080/01621459.2017.1319839>