

Guía de Estudio: Redes Neuronales y Deep Learning para Economistas

Basada en los capítulos iniciales de *Neural Networks and Deep Learning* de Michael Nielsen

Curso de Inteligencia Artificial con Aplicaciones en Economía II
Universidad Externado de Colombia

Esta guía busca traducir los conceptos iniciales de redes neuronales a un lenguaje familiar para estudiantes de Economía. No se concentra en derivaciones algebraicas profundas, sino en la intuición lógica, económica y computacional detrás de los modelos.

Índice

Objetivo de la guía	3
1. La Neurona como Agente Decisor	3
1.1. Del agente económico al perceptrón	3
1.2. Pesos: importancia relativa de los predictores	4
1.3. Sesgo: umbral o costo de entrada	4
1.4. Limitación del perceptrón	4
2. Funciones de Activación: Flexibilidad en la Decisión	4
2.1. ¿Por qué necesitamos funciones de activación?	4
2.2. La función sigmoide	5
2.3. De perceptrón a neurona sigmoide	5
2.4. ReLU: una activación simple y poderosa	5
2.5. Función de activación y flexibilidad del modelo	6
3. Arquitectura: El Mercado de Información	6
3.1. Capas de una red neuronal	6
3.2. Diagrama de una red simple	6
3.3. Capas ocultas: transformaciones intermedias	7
3.4. Deep Learning: profundidad como jerarquía de conceptos	7
3.5. Capacidad expresiva	7
4. Aprendizaje: Minimizando el Error Estructural	7
4.1. La función de costo	7
4.2. Descenso del gradiente	8
4.3. Tasa de aprendizaje	8
4.4. Stochastic Gradient Descent	8
4.5. Backpropagation	9
Glosario para Economistas	9

Trade-offs: Complejidad, Generalización y Overfitting	9
Ejemplo aplicado: predicción de riesgo de default	10
Preguntas de repaso	11

Objetivo de la guía

Las redes neuronales suelen presentarse como modelos “misteriosos” o cajas negras. Sin embargo, muchas de sus ideas básicas pueden entenderse usando herramientas conceptuales familiares para economistas: elección binaria, funciones de utilidad, optimización, minimización de costos, predicción fuera de muestra y trade-offs entre ajuste y generalización.

El objetivo de esta guía es construir un puente entre:

- modelos econométricos clásicos;
- problemas de optimización;
- aprendizaje automático;
- y redes neuronales.

La guía se inspira en los capítulos iniciales del libro gratuito de Michael Nielsen, *Neural Networks and Deep Learning*, especialmente en sus explicaciones sobre perceptrones, neuronas sigmoideas, descenso del gradiente, backpropagation, regularización y redes profundas.¹

1. La Neurona como Agente Decisor

1.1. Del agente económico al perceptrón

En economía, con frecuencia modelamos agentes que toman decisiones a partir de información disponible. Por ejemplo, una persona decide si acepta un crédito, una empresa decide si invierte, o un consumidor decide si compra un bien.

Un **perceptrón** puede entenderse como un agente decisor muy simple. Recibe información, pondera esa información y toma una decisión binaria.

$$\text{Decisión} = \begin{cases} 1, & \text{si la evidencia supera cierto umbral} \\ 0, & \text{si la evidencia no supera ese umbral} \end{cases}$$

Formalmente, el perceptrón calcula:

$$z = w_1x_1 + w_2x_2 + \dots + w_kx_k + b$$

y luego decide:

$$\text{output} = \begin{cases} 1, & \text{si } z > 0 \\ 0, & \text{si } z \leq 0 \end{cases}$$

Intuición central

Un perceptrón es como un modelo de elección binaria extremadamente simple: combina predictores, los pondera y toma una decisión de tipo “sí/no”.

¹Michael Nielsen, *Neural Networks and Deep Learning*. Disponible en: <http://neuralnetworksanddeeplearning.com/>

1.2. Pesos: importancia relativa de los predictores

Los pesos w_i indican qué tan importante es cada variable de entrada para la decisión final. En un modelo econométrico, cuando estimamos algo como:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

los coeficientes β_i indican la relación entre cada predictor y la variable dependiente, manteniendo lo demás constante. En una neurona artificial, los pesos cumplen un papel parecido, aunque su interpretación causal no debe asumirse automáticamente.

Analogía económica

Si una entidad financiera decide si aprueba un crédito, puede usar variables como ingreso, historial crediticio y deuda previa. Los pesos indican cuánta importancia le da el modelo a cada predictor al formar su decisión.

1.3. Sesgo: umbral o costo de entrada

El término b , llamado **bias** o sesgo, desplaza el umbral de activación de la neurona.

Una forma económica de entenderlo es como un **costo de entrada** o una barrera institucional. Si el sesgo hace más difícil activar la neurona, el agente requiere mayor evidencia para tomar la decisión positiva.

$$z = w \cdot x + b$$

Si b es muy negativo, se necesita mucha evidencia positiva en $w \cdot x$ para que la neurona se active. Si b es positivo, la neurona se activa más fácilmente.

Sesgo como umbral institucional

Piense en una política pública que exige muchos requisitos antes de otorgar un subsidio. El bias funciona como ese umbral: hace más fácil o más difícil que la decisión final sea positiva.

1.4. Limitación del perceptrón

El problema del perceptrón clásico es que su decisión cambia de forma brusca. Pequeños cambios en los pesos o en los datos pueden mover la salida de 0 a 1.

Esto hace difícil aprender de manera gradual.

En economía, sería como un modelo institucional que cambia radicalmente de decisión ante una variación mínima del ingreso declarado. En la práctica, muchas decisiones no son tan discretas: hay zonas grises, probabilidades y márgenes de incertidumbre.

2. Funciones de Activación: Flexibilidad en la Decisión

2.1. ¿Por qué necesitamos funciones de activación?

La función de activación transforma el valor interno de la neurona:

$$z = w \cdot x + b$$

en una salida:

$$a = f(z)$$

Sin funciones de activación no lineales, una red neuronal de muchas capas sería simplemente una combinación lineal de combinaciones lineales. En otras palabras, no ganaría capacidad frente a una regresión lineal más grande.

Idea clave

La no-linealidad es lo que permite que una red neuronal capture patrones complejos. Sin activaciones no lineales, la profundidad de la red no aporta verdadera flexibilidad.

2.2. La función sigmoide

La función sigmoide es:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Su salida siempre está entre 0 y 1. Esto la hace natural para interpretar resultados como probabilidades.

$$0 < \sigma(z) < 1$$

Analogía con elección binaria

La sigmoide se parece a una regresión logística. En lugar de decir simplemente “sí” o “no”, entrega una probabilidad suave de ocurrencia. Por ejemplo: probabilidad de default, probabilidad de pobreza o probabilidad de abandono escolar.

2.3. De perceptrón a neurona sigmoideal

El perceptrón toma decisiones duras:

$$0 \text{ o } 1$$

La neurona sigmoideal toma decisiones suaves:

$$0,13, 0,52, 0,91$$

Esto permite que pequeños cambios en los pesos generen pequeños cambios en la salida. Esa suavidad es crucial para entrenar la red mediante métodos de optimización.

2.4. ReLU: una activación simple y poderosa

Otra función de activación ampliamente usada es ReLU:

$$\text{ReLU}(z) = \max(0, z)$$

Si z es negativo, la salida es 0. Si z es positivo, la salida es z .

Intuición de ReLU

ReLU se puede interpretar como una regla de activación parcial: si la señal no supera cero, no se transmite; si la señal es positiva, se deja pasar. Es simple, computacionalmente eficiente y útil para redes profundas.

2.5. Función de activación y flexibilidad del modelo

En economía, muchas relaciones no son lineales:

- el efecto del ingreso sobre el consumo puede cambiar por tramos;
- la probabilidad de default puede aumentar bruscamente después de cierto nivel de deuda;
- el impacto de la educación sobre salarios puede depender del sector laboral;
- la inflación puede responder de forma no lineal a choques de oferta.

Las funciones de activación permiten que las redes neuronales aproximen este tipo de relaciones más flexibles.

3. Arquitectura: El Mercado de Información

3.1. Capas de una red neuronal

Una red neuronal está organizada en capas:

- **Capa de entrada:** recibe los datos originales.
- **Capas ocultas:** transforman la información.
- **Capa de salida:** produce la predicción final.


Analogía: mercado de información

Imagine una economía donde la información fluye entre agentes. Algunos agentes reciben datos básicos, otros procesan señales intermedias y al final una institución toma una decisión agregada. Una red neuronal funciona de manera similar: transforma información capa por capa.

3.2. Diagrama de una red simple

El siguiente diagrama muestra una red neuronal con:

- tres neuronas de entrada;
- cuatro neuronas en una capa oculta;
- una neurona de salida.



3.3. Capas ocultas: transformaciones intermedias

Las capas ocultas no son “misteriosas”. Simplemente son niveles intermedios de procesamiento. En un problema de predicción de riesgo crediticio, por ejemplo:

- la primera capa puede detectar señales simples: bajo ingreso, alta deuda, historial irregular;
- la segunda capa puede combinar esas señales en perfiles de riesgo;
- la salida produce una probabilidad de default.

3.4. Deep Learning: profundidad como jerarquía de conceptos

Una red profunda tiene múltiples capas ocultas. La idea es que las primeras capas aprendan patrones simples y las capas posteriores combinen esos patrones en representaciones más abstractas.

Interpretación económica

En análisis económico, esto se parece a pasar de variables observables a constructos latentes. Por ejemplo, ingreso, educación y ocupación pueden combinarse en una representación implícita de estatus socioeconómico.

3.5. Capacidad expresiva

Una de las ideas centrales de los capítulos iniciales de Nielsen es que las redes neuronales pueden aproximar funciones complejas. Esto no significa que siempre lo hagan bien, ni que sean automáticamente mejores que modelos simples. Significa que tienen una gran capacidad representacional.

En economía aplicada, esto puede ser útil cuando la relación entre variables es compleja, no lineal y difícil de especificar manualmente.

4. Aprendizaje: Minimizando el Error Estructural

4.1. La función de costo

Para aprender, la red necesita saber qué tan mal está prediciendo. Para eso usamos una **función de costo** o **loss function**.

Una función común para regresión es el error cuadrático medio:

$$C(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

La red intenta encontrar pesos y sesgos que minimicen esta función.

Analogía económica

Esto es similar a una firma que minimiza costos o a un planificador que minimiza una función de pérdida social. La diferencia es que aquí los instrumentos de decisión son los pesos y sesgos del modelo.

4.2. Descenso del gradiente

El descenso del gradiente es un método de optimización. Su idea central es:

Si estamos en una montaña de errores, damos pequeños pasos en la dirección en la que el error disminuye más rápido.

Formalmente, los pesos se actualizan así:

$$w \leftarrow w - \eta \frac{\partial C}{\partial w}$$

donde:

- w representa un peso;
- C es la función de costo;
- η es la tasa de aprendizaje;
- $\frac{\partial C}{\partial w}$ indica cómo cambia el costo cuando cambia ese peso.

Descenso del gradiente como optimización

Para un economista, el descenso del gradiente es simplemente un método numérico para minimizar una función objetivo. La red aprende porque ajusta sus parámetros en la dirección que reduce el error.

4.3. Tasa de aprendizaje

La tasa de aprendizaje η controla el tamaño de los pasos.

- Si η es muy pequeña, el aprendizaje será lento.
- Si η es muy grande, el modelo puede saltarse el mínimo.

Analogía

Es como ajustar una política monetaria. Cambios demasiado pequeños pueden no corregir el problema; cambios demasiado grandes pueden generar inestabilidad.

4.4. Stochastic Gradient Descent

En vez de calcular el gradiente usando todos los datos, el **descenso de gradiente estocástico** usa pequeños subconjuntos llamados mini-batches.

Esto tiene dos ventajas:

- reduce el costo computacional;
- introduce ruido útil que puede ayudar a escapar de soluciones pobres.

$$w \leftarrow w - \eta \nabla C_{\text{mini-batch}}$$

4.5. Backpropagation

Backpropagation es el algoritmo que permite calcular eficientemente cómo cada peso contribuye al error final.

La idea intuitiva es:

1. la red hace una predicción;
2. se calcula el error;
3. el error se propaga hacia atrás;
4. cada peso recibe una señal de “responsabilidad”;
5. los pesos se actualizan para reducir futuros errores.

Backpropagation como asignación de responsabilidad

Piense en una cadena de decisiones institucionales. Si el resultado final fue malo, se debe identificar qué etapas contribuyeron más al error. Backpropagation hace algo parecido: asigna responsabilidad matemática a cada peso de la red.

Glosario para Economistas

Concepto en ML	Traducción intuitiva	Analogía económica
Peso (<i>weight</i>)	Importancia de una entrada	Coefficiente o ponderador de un predictor
Bias	Umbral de activación	Costo de entrada o barrera institucional
Función de activación	Regla que transforma la señal	Función de decisión o utilidad transformada
Loss / Cost Function	Medida del error del modelo	Función de pérdida social o costo a minimizar
Gradient Descent	Método de minimización iterativa	Optimización numérica bajo incertidumbre
Stochastic Gradient Descent	Optimización con mini-muestras	Aprendizaje gradual usando información parcial
Backpropagation	Cálculo eficiente de responsabilidades	Auditoría del error dentro de una cadena de decisión
Overfitting	Memorizar ruido de la muestra	Confundir ruido del mercado con estructura real
Regularización	Penalización a la complejidad	Restricción institucional para evitar decisiones excesivamente flexibles

Trade-offs: Complejidad, Generalización y Overfitting

El problema

Un modelo más complejo puede ajustarse mejor a los datos de entrenamiento. Pero eso no garantiza que prediga mejor datos nuevos.

Este es uno de los problemas centrales del aprendizaje automático:

Buen ajuste en entrenamiento $\neq$ buena generalización

Overfitting

El **overfitting** ocurre cuando un modelo aprende detalles particulares, errores o ruido de la muestra de entrenamiento, en lugar de aprender la estructura general del fenómeno.

Analogía económica

Un modelo con overfitting es como un analista que cree haber descubierto una ley del mercado, pero en realidad solo memorizó anomalías de una muestra histórica específica.

Ejemplo:

- Un modelo de inflación puede aprender patrones muy específicos de una crisis pasada.
- Si esos patrones no se repiten, el modelo fallará fuera de muestra.

Sesgo y varianza

El trade-off clásico es:

- **Alto sesgo:** modelo demasiado simple, no captura la estructura.
- **Alta varianza:** modelo demasiado flexible, se adapta demasiado a la muestra.

$$\text{Error total} \approx \text{sesgo}^2 + \text{varianza} + \text{error irreducible}$$

Lectura práctica

El objetivo no es minimizar el error de entrenamiento, sino encontrar un modelo que generalice bien. En economía aplicada, esto equivale a preferir un modelo que prediga razonablemente en contextos nuevos, no uno que explique perfectamente el pasado.

Regularización

La regularización introduce restricciones o penalizaciones para evitar que el modelo sea excesivamente complejo.

En términos intuitivos:

La regularización le dice al modelo: “puedes aprender patrones, pero no inventes una explicación demasiado complicada si una más simple funciona bien”.

Esto se conecta con técnicas discutidas por Nielsen para mejorar la forma en que aprenden las redes, como mejores funciones de costo, regularización y estrategias para ajustar hiperparámetros.

Ejemplo aplicado: predicción de riesgo de default

Suponga que queremos predecir si una empresa incumplirá un crédito. Tenemos las siguientes variables:

- x_1 : nivel de deuda;

- x_2 : ingreso operativo;
- x_3 : historial de pagos;
- x_4 : antigüedad de la empresa.

Un modelo lineal puede estimar:

$$P(\text{default} = 1) = f(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4)$$

Una red neuronal permite que el efecto de cada variable dependa de combinaciones más complejas:

- deuda alta puede ser riesgosa solo si el ingreso operativo es bajo;
- empresas jóvenes pueden ser más riesgosas, pero no si tienen historial de pagos sólido;
- ciertos patrones pueden emerger solo al combinar muchas señales.

Conclusión aplicada

La red neuronal no reemplaza el razonamiento económico. Lo complementa cuando las relaciones son no lineales, interactivas o difíciles de especificar manualmente.

Preguntas de repaso

1. ¿En qué se parece un perceptrón a un modelo de elección binaria?
2. ¿Por qué el bias puede interpretarse como un umbral institucional?
3. ¿Por qué una neurona sigmoideal facilita el aprendizaje frente a un perceptrón?
4. ¿Qué aporta una función de activación no lineal?
5. ¿Por qué una red con muchas capas lineales sigue siendo equivalente a una transformación lineal?
6. ¿Qué representa la función de costo?
7. ¿Cómo se relaciona el descenso del gradiente con la minimización de una función objetivo?
8. ¿Qué hace backpropagation en términos intuitivos?
9. ¿Por qué el overfitting es peligroso en predicción económica?
10. ¿Cuál es el trade-off entre complejidad y generalización?

Cierre

Las redes neuronales pueden parecer distantes de la formación tradicional en economía. Sin embargo, sus fundamentos conectan con ideas conocidas: elección, ponderación de variables, umbrales, optimización, minimización de pérdidas y generalización fuera de muestra.

La clave para un economista no es memorizar fórmulas, sino entender qué está haciendo el modelo:

- transforma información;

- ajusta parámetros;
- minimiza errores;
- y busca patrones que generalicen.

Mensaje final

Una red neuronal no es una caja mágica. Es una máquina de optimización flexible. Su valor depende de que el economista entienda el problema, seleccione buenas variables, evalúe el desempeño fuera de muestra y mantenga criterio económico.